

Aula 5: Treinar é otimizar — descida de gradiente e suas variações

SGD e mini-batch • momentum • Adam • inicialização

Prof. Marcelo Keese Albertini

GBC073 — Inteligência Computacional • Universidade Federal de Uberlândia
2026



- ▶ **As três descidas:** batch, estocástica e mini-batch

- ▶ **As três descidas:** batch, estocástica e mini-batch
- ▶ **Momentum e descida acelerada**

- ▶ **As três descidas:** batch, estocástica e mini-batch
- ▶ **Momentum e descida acelerada**
- ▶ **Métodos adaptativos:** AdaGrad, RMSProp, Adam

- ▶ **As três descidas:** batch, estocástica e mini-batch
- ▶ **Momentum e descida acelerada**
- ▶ **Métodos adaptativos:** AdaGrad, RMSProp, Adam
- ▶ **Inicialização e taxas de aprendizado**

PARTE 1

As três descidas



As três descidas (batch, estocástica, mini-batch)

- ▶ Em lote: gradiente exato, caro, sem ruído
- ▶ Estocástica (SGD): um exemplo por passo — ruído alto, escapa de mínimos ruins, converge devagar
- ▶ Mini-batch: o meio-termo prático; o ruído vira aliado
- ▶ Compromisso exploração / exploração dentro do próprio treino

PARTE 2

Momentum e descida acelerada



- ▶ Momentum: acumula velocidade na direção consistente do gradiente
- ▶ Atravessa platôs e vales estreitos mais rápido
- ▶ NAG (Nesterov): avalia o gradiente *à frente*, onde a velocidade já levou
- ▶ Interpretação física: bola rolando vs. degrau a cada passo

PARTE 3

Métodos adaptativos



- ▶ AdaGrad: taxa por parâmetro, dividida pela soma histórica dos gradientes ao quadrado — morre devagar
- ▶ RMSProp: média móvel em vez de soma — esquece o passado distante
- ▶ Adam: momentum + RMSProp, com correção de viés no início do treino
- ▶ Adam é o padrão de fato em deep learning; entenda o que ajusta

PARTE 4

Inicialização e taxas de aprendizado



- ▶ Inicialização importa: pesos constantes ou grandes demais matam o sinal (ou o gradiente)
- ▶ Xavier/Glorot e He: variância calibrada pela largura da camada
- ▶ Taxa de aprendizado: pequena demais é lenta; grande demais diverge
- ▶ Agendamentos (*schedules*): decaimento, warm-up, cosine annealing

Para discutir em aula

Adam com taxa $\eta = 1$ tende a convergir mais rápido do que com $\eta = 10^{-3}$, pois aprende com passos maiores.

Verdadeiro / Falso