

Aula 6: A rede que decora — sobreajuste, regularização e generalização

Viés e variância • validação • dropout • weight decay

Prof. Marcelo Keese Albertini

GBC073 — Inteligência Computacional • Universidade Federal de Uberlândia
2026



- ▶ **O sobreajuste e o dilema viés-variância**

- ▶ **O sobreajuste e o dilema viés-variância**
- ▶ **Validação, early stopping e conjunto de teste**

- ▶ **O sobreajuste e o dilema viés-variância**
- ▶ **Validação, early stopping e conjunto de teste**
- ▶ **Regularização explícita:** weight decay e dropout

- ▶ **O sobreajuste e o dilema viés-variância**
- ▶ **Validação, early stopping e conjunto de teste**
- ▶ **Regularização explícita:** weight decay e dropout
- ▶ **Normalização e aumento de dados**

PARTE 1

O sobreajuste e o dilema viés-variância



- ▶ Sobreajuste (*overfitting*): decorar o conjunto de treino e falhar no que não viu
- ▶ Erro de generalização = viés (modelo simples demais) + variância (sensível demais ao sorteio dos dados) + ruído
- ▶ Redes grandes têm variância alta — daí a fama de “decorar”
- ▶ Mas redes grandes *com* regularização costumam generalizar melhor (contra-intuição importante)

PARTE 2

Validação, early stopping e conjunto de teste



- ▶ Três partições: treino (ajusta), validação (decide), teste (relata — só uma vez)
- ▶ *Early stopping*: parar quando o erro de validação para de cair
- ▶ Escolher hiperparâmetros pelo teste vaza o teste — vício sutil
- ▶ Curvas de aprendizado como ferramenta de diagnóstico

PARTE 3

Regularização explícita



- ▶ Weight decay (L_2 nos pesos): penaliza pesos grandes, encolhe para soluções simples
- ▶ Dropout: sorteia neurônios desligados a cada passo — a rede aprende a ser redundante
- ▶ Dropout como *ensemble* barato: média implícita de muitas redes
- ▶ Em teste, nada é desligado (ou se re-escala a ativação)

Intuição

Regularizar não é castigar a rede — é impedir que ela memorize o que não deveria existir como regra.

PARTE 4

Normalização e aumento de dados



- ▶ Normalização de lote (*batch norm*): estabiliza a distribuição das ativações — treina mais rápido e regulariza de brinde
- ▶ Aumento de dados (*data augmentation*): fabricar exemplos plausíveis (rotações, ruído, recortes)
- ▶ A regularização mais barata costuma ser mais dados — reais ou sintéticos